

PROYECTOS PIA's

Proyectos de Investigación Aplicada Gestión de Proyectos Informáticos 2026 -I

PERFIL DE PROYECTO

PROYECTO PAINPREDICT NEURO

Sección 302 – Profesor: Eduardo Osorio

COORDINADOR ACADEMICO

Dr. Oscar Eduardo Magna Veloso
Ing. Civil en Informática
Dr. en Administración y Dirección de Empresas & MBA
Departamento de Informática y Computación
omagna@utem.cl, osemav@gmail.com

Marzo 2026

UNIVERSIDAD TECNOLÓGICA METROPOLITANA

Facultad de Ingeniería · Depto. de Informática y Computación

Gestión de Proyectos Informáticos

PERFIL DE PROYECTO

GPI-1 · Prioridad 1 - Ranking Atractividad Global: 9.60 / 10

PainPredict_Neuro

Impacto de la Inteligencia Emocional en el Neurodesarrollo mediante Tecnologías de Inteligencia Artificial

Neurociencia Afectiva · Psicometría · Inteligencia Artificial

Innovación: 9.0 · Novedad: 9.0 · Valor Agregado: 10.0 · Aporte: 10.0

Proyecto Nuevo - 2026

Marco de Trabajo: Magna, Oscar (2026) · v3 · UTEM, Chile

UNIVERSIDAD TECNOLÓGICA METROPOLITANA

Facultad de Ingeniería · Depto. de Informática y Computación

Gestión de Proyectos Informáticos

PERFIL DE PROYECTO

GPI-2 · Prioridad 1 · Ranking Global: 9.60 / 10

PainPredict Neuro

**Machine Learning sobre señales EEG y respuestas autonómicas
para la cuantificación objetiva del dolor en pacientes no comunicativos**

Innovación: 9.0 · Novedad: 9.0 · Valor Agregado: 10.0 · Aporte: 10.0

Proyecto Nuevo — 2026

Marco de Trabajo: Magna, Oscar (2026) · v3 · UTEM, Chile

Tabla de Contenidos

TABLA DE CONTENIDOS	4
FICHA DE IDENTIFICACIÓN DEL PROYECTO	5
1. CONTEXTO	6
2. ALCANCE	7
3. OBJETIVO GENERAL	7
4. OBJETIVOS ESPECÍFICOS	8
5. HIPÓTESIS	8
5.1. HIPÓTESIS PRINCIPAL	8
5.2. HIPÓTESIS ESPECÍFICAS	9
6. INTERROGANTES A RESOLVER	9
6.1. INTERROGANTES DE INVESTIGACIÓN	9
6.2. INTERROGANTES CLÍNICAS Y ÉTICAS	9
6.3. INTERROGANTES TECNOLÓGICAS	10
7. CONSIDERACIONES GENERALES PARA EL DISEÑO	10
7.1. DESCRIPCIÓN DEL SISTEMA	10
7.2. PIPELINE PROPUESTO	11
7.3. CONJUNTO DE DATOS	11
<i>Datasets Primarios — Señales EEG y Dolor</i>	11
<i>Datasets Complementarios — Señales Autonómicas</i>	12
<i>Instrumentos Clínicos de Referencia (Ground Truth)</i>	12
7.4. TAREAS GENERALES DEL PROYECTO	12
7.5. CONSIDERACIONES ESPECIALES	13
<i>Consideraciones Éticas — CRÍTICO</i>	13
<i>Consideraciones Técnicas</i>	13
7.6. BASES DE DATOS — REFERENCIAS INICIALES	13
8. TAREAS GENERALES DEL PROYECTO POR FASE	13
8.1. FASE 1: INVESTIGACIÓN INICIAL Y PLANIFICACIÓN DEL PROYECTO	14
<i>Objetivos de la Fase</i>	14
<i>Tareas Principales</i>	14
<i>Entregables</i>	14
8.2. FASE 2: ADQUISICIÓN Y PREPARACIÓN DE DATOS	14
<i>Objetivos de la Fase</i>	14
<i>Tareas Principales</i>	14
<i>Entregables</i>	15
8.3. FASE 3: ANÁLISIS EXPLORATORIO DE DATOS (EDA)	15
<i>Objetivos de la Fase</i>	15
<i>Tareas Principales</i>	15
<i>Entregables</i>	15
8.4. FASE 4: DISEÑO, ENTRENAMIENTO Y VALIDACIÓN DE MODELOS	15
<i>Objetivos de la Fase</i>	15
<i>Estrategia de Validación</i>	16
<i>Entregables</i>	16
8.5. FASE 5: XAI, DASHBOARD CLÍNICO Y ANÁLISIS DE EQUITAD	16
<i>Objetivos de la Fase</i>	16
<i>Tareas Principales — XAI</i>	17
<i>Tareas Principales — Dashboard Clínico</i>	17
<i>Tareas Principales — Análisis de Equidad</i>	17
<i>Entregables</i>	17
8.6. FASE 6: ANÁLISIS DE RESULTADOS, INTERPRETACIÓN E INFORME FINAL	17
<i>Objetivos de la Fase</i>	17
<i>Tareas Principales</i>	17
<i>Entregables</i>	18
8.7. HERRAMIENTAS RECOMENDADAS	18
8.8. CONCLUSIÓN	19
9. ANEXOS	20
9.1. BASES DE DATOS Y REFERENCIAS INICIALES	20
<i>Referencias Bibliográficas Clave</i>	20
9.2. ESCALAS CLÍNICAS DE REFERENCIA PARA EL GROUND TRUTH	21
9.3. GLOSARIO DE TÉRMINOS TÉCNICOS	22

Ficha de Identificación del Proyecto

ID del Proyecto	GPI-2
Ranking Global	9.60 / 10 (Innovación: 9.0 · Novedad: 9.0 · Valor Agregado: 10.0 · Aporte: 10.0)
Prioridad	1 (Mayor)
Nombre del Proyecto	PainPredict Neuro
Título Completo	ML sobre señales EEG y respuestas autonómicas para cuantificar objetivamente el dolor crónico y agudo en pacientes no comunicativos
Área Temática	Neurociencia Computacional, Bioingeniería, Machine Learning Clínico, Analgesia Personalizada
Población Objetivo	Pacientes no comunicativos: recién nacidos, personas con demencia avanzada, pacientes sedados en UCI
Tipo de Proyecto	Investigación Aplicada con Prototipo Funcional — Proyecto Nuevo
Asignatura	Gestión de Proyectos Informáticos (GPI)
Institución	Depto. de Informática y Computación, Facultad de Ingeniería, UTEM
Marco de Trabajo	Magna, Oscar (2026). Marco de Trabajo para Proyectos de Titulación v3. UTEM, Chile.

1. Contexto

La evaluación del dolor constituye uno de los desafíos clínicos más complejos y éticamente urgentes de la medicina contemporánea. En condiciones normales, el dolor se evalúa mediante escalas subjetivas de autorreporte (NRS, VAS, FACES) que requieren la capacidad comunicativa del paciente. Sin embargo, existe una población significativa de pacientes que, por su condición, son incapaces de expresar verbalmente su experiencia dolorosa: neonatos y recién nacidos prematuros, pacientes con demencia avanzada o deterioro cognitivo severo, y pacientes sedados o con ventilación mecánica en unidades de cuidados intensivos (UCI).

En estas poblaciones, la imposibilidad de autorreporte genera una problemática clínica de alta consecuencia: el infratratamiento del dolor conlleva sufrimiento innecesario, alteraciones del neurodesarrollo en neonatos, mayor mortalidad en UCI y deterioro acelerado en pacientes con demencia; mientras que el sobreuso de opiáceos implica riesgos de dependencia, depresión respiratoria, hipotensión y muerte. El uso excesivo de opioides durante la pandemia de COVID-19 en pacientes sedados ventilados evidenció dramáticamente este problema a escala global.

Ante este escenario, la Neurociencia Computacional y el Machine Learning ofrecen una oportunidad inédita: desarrollar un índice de dolor objetivo, continuo y personalizado, basado en biomarcadores neuronales y autonómicos capturables de forma no invasiva. Las señales EEG (electroencefalografía) codifican la respuesta cortical al dolor, mientras que las respuestas autonómicas (frecuencia cardíaca, variabilidad de la frecuencia cardíaca, conductancia de la piel, temperatura periférica) reflejan la activación del sistema nervioso autónomo ante el estímulo nociceptivo.

Problema Central del Proyecto

No existe actualmente un monitor de dolor objetivo, continuo y validado clínicamente para poblaciones no comunicativas, que integre señales EEG y biomarcadores autonómicos mediante modelos de Machine Learning. Los instrumentos disponibles (NIPS, FLACC, CPOT, ABBEY) son escalas observacionales dependientes del juicio subjetivo del clínico, con limitaciones de reproducibilidad y sensibilidad ante dolor de baja intensidad.

PainPredict Neuro se propone abordar este vacío mediante el desarrollo de un sistema de monitoreo de dolor basado en ML que analice de forma continua y en tiempo real las señales EEG y autonómicas del paciente, produciendo un índice de dolor objetivo (Pain Index, PI) que sirva de apoyo a la decisión clínica para el ajuste de analgesia personalizada, con especial foco en la prevención de la sobredosis opioide.

2. Alcance

Incluido en el Alcance

- Desarrollo del pipeline de adquisición y preprocesamiento de señales EEG (bandas delta, theta, alfa, beta, gamma) y señales autonómicas (ECG/HRV, GSR/EDA, temperatura, SpO2).
- Extracción de features neuronales y autonómicas relevantes para el análisis nociceptivo.
- Entrenamiento y validación de modelos ML/DL para clasificación y cuantificación del dolor.
- Desarrollo de un índice de dolor compuesto (Pain Index) con valor continuo y umbral de alerta clínica.
- Incorporación de explicabilidad (XAI) para soporte a la decisión clínica.
- Desarrollo de prototipo de dashboard clínico para visualización en tiempo real.
- Validación del modelo con datasets públicos validados clínicamente.
- Análisis de sesgo del modelo según grupos de población (neonatos, adultos mayores, UCI).

Fuera del Alcance

- Desarrollo de hardware de adquisición EEG propio (se usan datasets y dispositivos existentes).
- Integración con sistemas HIS/EHR hospitalarios (fuera del alcance del prototipo académico).
- Diagnóstico clínico certificado: el sistema es exclusivamente una herramienta de apoyo.
- Validación clínica formal con pacientes reales en protocolo IRB (requiere fase posterior).
- Desarrollo de solución para dolor agudo postoperatorio en pacientes conscientes.
- Prescripción automática de analgesia (la decisión siempre recae en el médico tratante).

Ámbito de aplicación primario: Unidades de Cuidados Intensivos (UCI), Unidades de Neonatología y Unidades de Cuidados Paliativos de hospitales de mediana y alta complejidad.

3. Objetivo General

Desarrollar un sistema de monitoreo del dolor basado en Machine Learning que integre señales EEG y biomarcadores autonómicos para cuantificar de forma objetiva, continua y explicable el nivel de dolor en pacientes no comunicativos, produciendo un índice de dolor validado (Pain Index) que apoye la toma de decisiones clínicas para el ajuste personalizado de analgesia y la prevención de sobredosis opiode en poblaciones vulnerables.

4. Objetivos Específicos

1. Realizar una revisión bibliométrica y alométrica del estado del arte en neurociencia del dolor, procesamiento de señales EEG, biomarcadores autonómicos del dolor y modelos de ML aplicados a la evaluación nociceptiva objetiva.
2. Adquirir, integrar y preprocesar datasets de señales EEG y autonómicas de pacientes en contextos de dolor clínicamente validado, asegurando la calidad, representatividad y privacidad de los datos.
3. Extraer y seleccionar features relevantes en dominio temporal, frecuencial y tiempo-frecuencial de las señales EEG (bandas delta-gamma, conectividad cortical) y autonómicas (HRV, SCR, temperatura).
4. Diseñar, entrenar y validar modelos de ML/DL para la clasificación y cuantificación del dolor, incluyendo modelos especializados por subpoblación (neonatos, adultos, sedados en UCI).
5. Construir el Pain Index: un índice de dolor continuo y compuesto que integre las salidas de los modelos individuales mediante técnicas de fusión de señales y aprendizaje de ensemble.
6. Implementar técnicas de Explainable AI (XAI) que permitan al clínico comprender qué biomarcadores están determinando el índice de dolor en cada caso particular.
7. Desarrollar un prototipo de dashboard clínico que visualice el Pain Index en tiempo real, con alertas configurables, historial de evolución y exportación de reportes clínicos.
8. Analizar la equidad y el sesgo del modelo entre subpoblaciones, evaluando su rendimiento diferencial y formulando estrategias de mitigación de sesgo.

5. Hipótesis

5.1. Hipótesis Principal

H1: Un modelo de Machine Learning entrenado sobre features extraídas de señales EEG y biomarcadores autonómicos puede cuantificar el nivel de dolor en pacientes no comunicativos con precisión clínicamente aceptable ($AUC \geq 0.80$), superando el desempeño de las escalas observacionales conductuales existentes (NIPS, FLACC, CPOT) en términos de objetividad, reproducibilidad y sensibilidad ante dolor de baja intensidad.

5.2. Hipótesis Específicas

- H2: La fusión de señales EEG y autonómicas producirá un modelo de mayor precisión diagnóstica que cualquiera de las modalidades por separado, con una mejora estadísticamente significativa del AUC ($p < 0.05$).
- H3: Las features en el dominio frecuencial de la señal EEG (especialmente bandas delta y gamma) serán los predictores más relevantes del nivel de dolor según análisis SHAP, en coherencia con la literatura neurofisiológica del dolor.
- H4: Un modelo especializado por subpoblación (neonato vs. adulto vs. UCI sedado) obtendrá mejor rendimiento que un modelo generalista entrenado sobre el conjunto combinado.
- H5: La incorporación de técnicas de XAI (SHAP, LIME) permitirá identificar patrones de biomarcadores diferenciados entre dolor crónico y dolor agudo.
- H6: El Pain Index producido por el sistema mostrará una correlación positiva y estadísticamente significativa ($r \geq 0.70$) con las escalas observacionales de referencia (CPOT, NIPS) en los datos de validación.

6. Interrogantes a Resolver

6.1. Interrogantes de Investigación

- ¿Cuáles son los biomarcadores EEG y autonómicos más robustos y reproducibles para la evaluación objetiva del dolor en cada subpoblación objetivo (neonatos, demencia, UCI)?
- ¿Qué arquitecturas de modelos ML/DL ofrecen el mejor equilibrio entre precisión diagnóstica, interpretabilidad clínica y eficiencia computacional para el análisis de señales biosensoriales en tiempo real?
- ¿En qué medida los modelos de dolor entrenados sobre señales EEG de adultos son transferibles mediante fine-tuning a la población neonatal, dado el estado de maduración diferencial del SNC?
- ¿Qué estrategias de manejo de datos desbalanceados son más efectivas en el contexto de datasets de dolor, donde los episodios de dolor severo son eventos de menor frecuencia relativa?
- ¿Cómo afecta la variabilidad inter-individual y la medicación analgésica previa a la señal EEG y a la capacidad predictiva de los modelos?

6.2. Interrogantes Clínicas y Éticas

- ¿Cuál es el umbral clínicamente significativo del Pain Index que debe activar una alerta de intervención analgésica, y cómo puede calibrarse por tipo de paciente y contexto clínico?
- ¿Qué nivel de explicabilidad es necesario para que un médico intensivista confíe en el Pain Index como apoyo a la decisión de ajuste de analgesia?
- ¿Cómo garantizar la equidad del modelo entre poblaciones con distintas características demográficas y neurológicas, evitando el infratratamiento del dolor en grupos históricamente subdiagnosticados?
- ¿Qué protocolos de privacidad y seguridad de datos son necesarios para el manejo de señales EEG de pacientes en estado crítico o con deterioro cognitivo?

6.3. Interrogantes Tecnológicas

- ¿Qué técnicas de filtrado y artefactos (ICA, bandpass, notch) son más efectivas para preprocesar señales EEG con alta presencia de ruido en entornos hospitalarios?
- ¿Es factible lograr inferencia en tiempo real (<500ms) sobre señales EEG con los modelos seleccionados en hardware de uso clínico estándar?
- ¿Qué mecanismo de fusión (weighted average, stacking, attention-based) optimiza la integración de las múltiples modalidades de señal biosensorial?

7. Consideraciones Generales para el Diseño

7.1. Descripción del Sistema

PainPredict Neuro es un sistema de monitoreo continuo del dolor basado en Machine Learning que analiza en tiempo real señales EEG multicanal y biomarcadores autonómicos (ECG, GSR, temperatura, SpO2) para producir el Pain Index (PI): un índice de dolor objetivo con valor continuo en escala 0-10, análogo en interpretación a la Escala Numérica de Dolor (NRS) pero generado exclusivamente a partir de señales fisiológicas objetivas.

El sistema está orientado a tres contextos clínicos distintos, cada uno con características de señal y requerimientos de modelo diferenciados:

Contexto Clínico	Población	Desafíos Específicos
Neonatología	Recién nacidos y prematuros (0-28 días)	EEG con maduración cortical incompleta; artefactos de movimiento elevados; alta variabilidad inter-sujeto; ausencia de verbal report.
Cuidados Paliativos / Demencia	Adultos mayores con demencia avanzada o deterioro cognitivo severo	Señal EEG con degeneración neuronal; polifarmacia que afecta la señal; sesgo por enfermedades comórbidas.
UCI / Ventilación Mecánica	Pacientes sedados, con ventilación mecánica o bajo BIS monitor	Alta presencia de artefactos eléctricos por equipamiento médico; efectos de sedantes en EEG; monitoreo continuo 24/7.

7.2. Pipeline Propuesto

N°	Etapa	Descripción
1	Adquisición de señales	Captura de EEG multicanal (8-32 ch, 250-1000 Hz), ECG (HRV), GSR/EDA, temperatura periférica y SpO2. En el prototipo: datos de datasets públicos validados clínicamente.
2	Preprocesamiento EEG	Filtrado banda (0.5-45 Hz), notch (50/60 Hz), remoción de artefactos (ICA, ASR), re-referenciado (CSD o promedio), segmentación en épocas (1-4s).
3	Preprocesamiento autonómico	Filtrado, detección de picos R (ECG), cálculo de HRV (SDNN, RMSSD, LF/HF), suavizado de GSR, extracción de SCR y tonic level.
4	Extracción de features EEG	Dominio frecuencial: PSD por banda (delta, theta, alpha, beta, gamma). Dominio tiempo-frecuencia: CWT, STFT, Hjorth parameters. Conectividad: PLV, coherencia, PAC.
5	Extracción de features autonómicas	HRV temporal y frecuencial, features de GSR (amplitud SCR, latencia, tiempo de recuperación), temperatura periférica (variabilidad, tendencia).
6	Selección de features	Análisis de importancia (SHAP, MI, ANOVA-F), eliminación de redundancia (PCA, correlación de Pearson), selección supervisada (RFE, LASSO).
7	Modelado ML/DL	Modelos por modalidad y ensemble fusion: RF, SVM, XGBoost, LSTM, CNN-EEG, Transformer para series de tiempo. Modelos especializados por subpoblación.
8	Pain Index (PI)	Fusión ponderada / stacking de las salidas de los modelos individuales en un índice continuo 0-10. Calibración por tipo de paciente.
9	XAI y Dashboard	SHAP values para explicabilidad. Visualización en tiempo real del PI, contribución por canal EEG y biomarcador, alertas y reportes clínicos.

7.3. Conjunto de Datos

El proyecto utilizará datasets públicos con anotaciones clínicas de dolor, complementados con literatura de referencia en neurofisiología del dolor. Dado que se trabaja con datos de pacientes vulnerables, el prototipo académico se basará exclusivamente en datasets de acceso público con aprobación ética certificada por sus autores originales.

Datasets Primarios — Señales EEG y Dolor

- BioVid Heat Pain Database (Walter et al., 2013): EEG de 8 canales + señales autonómicas (ECG, GSR, EMG) durante estimulación de dolor térmico controlado en 90 sujetos. Dataset de referencia en investigación de dolor con IA.
- DEAP Dataset (Koelstra et al., 2012): EEG 32 canales + señales autonómicas durante inducción emocional. Útil para transferencia de features de arousal/valencia (relacionados con respuesta al dolor).
- SEED Dataset (Zheng & Lu, 2015): EEG 62 canales durante inducción emocional. Para features de conectividad cortical transferibles al dominio del dolor.
- OpenNeuro Pain Datasets (openneuro.org): colección de datasets EEG/fMRI de dolor publicados bajo Open Science Framework.

Datasets Complementarios — Señales Autonómicas

- PhysioNet MIMIC-III / MIMIC-IV: señales fisiológicas de UCI (ECG, SpO2, temperatura, presión arterial) con anotaciones clínicas. Acceso restringido con acuerdo de datos.
- PhysioNet NICU Dataset: señales fisiológicas de unidad neonatal con eventos clínicos anotados.
- Neonatal Pain EEG Dataset (Hartley et al., 2017): EEG neonatal durante procedimientos dolorosos (punción de talón).

Instrumentos Clínicos de Referencia (Ground Truth)

- CPOT (Critical-Care Pain Observation Tool): escala conductual validada para UCI (ICC > 0.85 en literatura).
- NIPS (Neonatal Infant Pain Scale): escala para neonatos basada en expresión facial, llanto y postura.
- FLACC (Face, Legs, Activity, Cry, Consolability): escala conductual pediátrica y adultos no comunicativos.
- ABBEY Pain Scale: escala para personas con demencia avanzada.
- NRS (Numeric Rating Scale): escala de referencia para dolor en pacientes comunicativos (variable target de calibración).

7.4. Tareas Generales del Proyecto

- Pipeline de preprocesamiento EEG y señales autonómicas con control de calidad de señal.
- Ingeniería de features neuronales y autonómicos para clasificación/regresión de dolor.
- Entrenamiento y comparación de modelos ML/DL: RF, XGBoost, SVM, LSTM, CNN-EEG, Transformer.
- Construcción del Pain Index mediante fusión de modelos por modalidad y subpoblación.
- Análisis de equidad y sesgo del modelo entre subpoblaciones.
- Implementación de XAI (SHAP, LIME, GRAD-CAM para CNN-EEG).
- Desarrollo del dashboard clínico de visualización en tiempo real.

7.5. Consideraciones Especiales

Consideraciones Éticas — CRÍTICO

Protocolo Ético Obligatorio

Dado que el proyecto trabaja con datos de poblaciones clínicas vulnerables, se deben observar los siguientes principios:

- Uso exclusivo de datasets con aprobación ética certificada y acuerdo de uso de datos firmado.
- Prohibición absoluta de recolectar señales EEG de pacientes reales en el marco de este proyecto académico sin aprobación de Comité de Ética Científica.
- Protección de privacidad: todos los datos de pacientes deben estar completamente anonimizados antes de su uso.
- El Pain Index NO puede usarse con fines de diagnóstico clínico formal ni prescripción de medicamentos.
- Declaración explícita en toda publicación o presentación: 'Sistema de apoyo a la decisión clínica — no reemplaza el juicio médico'.
- Cumplimiento de los principios FAIR (Findable, Accessible, Interoperable, Reusable) en el manejo de datos.

Consideraciones Técnicas

- Artefactos EEG: el entorno clínico genera artefactos eléctricos de alta magnitud (respiradores, monitores). El pipeline de preprocesamiento debe ser robusto a estos artefactos.
- Sesgo por medicación: los sedantes, opiáceos y anestésicos modifican profundamente la señal EEG. El modelo debe incluir la medicación como variable de contexto.
- Latencia clínica: el sistema debe producir una actualización del Pain Index cada 30-60 segundos como mínimo para ser útil en contexto clínico.
- Generalización entre centros: los sistemas EEG de distintos fabricantes tienen características de hardware diferentes. El modelo debe ser evaluado en términos de generalización cross-device.
- Manejo de clases desbalanceadas: los episodios de dolor severo son eventos de menor frecuencia. Usar SMOTE, class weighting o técnicas de oversampling apropiadas.

7.6. Bases de Datos — Referencias Iniciales

Ver Sección 9.1 — Anexo: Bases de Datos y Referencias Iniciales.

8. Tareas Generales del Proyecto por Fase

El proyecto PainPredict Neuro se desarrolla en seis fases iterativas dentro del marco ScrumBan y el ciclo de Sprint de Desarrollo del Marco de Trabajo de Magna (2026).

8.1. Fase 1: Investigación Inicial y Planificación del Proyecto

Objetivos de la Fase

Establecer el marco teórico, bibliométrico y metodológico del proyecto, y elaborar el plan de trabajo detallado.

Tareas Principales

- Revisión bibliométrica y altmétrica en Scopus, WoS, IEEE y PubMed sobre: neurofisiología del dolor, EEG y dolor, ML aplicado a biosensores clínicos, evaluación del dolor en poblaciones no comunicativas.
- Definición del diseño metodológico: selección de features, modelos candidatos y estrategia de validación.
- Identificación, revisión y solicitud de acceso a los datasets primarios (BioVid, PhysioNet MIMIC, OpenNeuro).
- Definición del alcance detallado, WBS, OBS y cronograma (Gestión de Alcance — EVM).
- Configuración del entorno de desarrollo: repositorio Git, entorno virtual Python, herramientas MLOps.
- Elaboración del protocolo de uso ético de datos clínicos y firma de acuerdos de datos (PhysioNet DUA, etc.).
- Redacción del Informe de Anteproyecto (Propuesta de Proyecto).

Entregables

- Informe de Estado del Arte (estudio bibliométrico con índice H, análisis de citas, top de títulos).
- Marco Conceptual y Diseño Metodológico del Proyecto.
- Propuesta de Proyecto con WBS, cronograma, Curva S y análisis EVM inicial.
- Protocolos de uso ético de datos firmados.

8.2. Fase 2: Adquisición y Preparación de Datos

Objetivos de la Fase

Obtener, integrar, limpiar y preprocesar las señales EEG y autonómicas de los datasets seleccionados.

Tareas Principales

- Descarga e integración de los datasets: BioVid Heat Pain Database, PhysioNet MIMIC, Neonatal Pain EEG, DEAP.
- Implementación del pipeline de preprocesamiento EEG: filtrado, ICA, ASR, segmentación en épocas.
- Implementación del pipeline de preprocesamiento autonómico: detección de picos R, HRV, GSR tonic/phasic.
- Sincronización temporal entre modalidades EEG y autonómicas.
- Alineación de anotaciones clínicas (CPOT, NIPS, NRS) con ventanas temporales de señal.
- Manejo de datos faltantes y segmentos con artefactos irrecuperables.
- Estratificación del dataset por subpoblación (neonato, adulto UCI, demencia).
- Construcción del Dataset PainPredict v1 documentado y versionado con DVC.

Entregables

- Dataset PainPredict v1: señales preprocesadas, alineadas y documentadas.
- Scripts de preprocesamiento reproducibles (Python, MNE-Python, NeuroKit2).
- Reporte de calidad del dataset: estadísticas descriptivas, distribución de clases, análisis de artefactos.

8.3. Fase 3: Análisis Exploratorio de Datos (EDA)

Objetivos de la Fase

Explorar la estructura estadística y espectral del dataset para guiar la selección de features y el diseño de modelos.

Tareas Principales

- Análisis espectral de señales EEG por condición (dolor/no dolor) y subpoblación: comparación de PSD por banda.
- Análisis de variabilidad de la frecuencia cardíaca (HRV) en función de la intensidad del dolor.
- Análisis de correlación entre features EEG, features autonómicas e índices clínicos (CPOT, NRS, NIPS).
- Visualización de mapas topográficos EEG por estado de dolor (heatmaps por canal y banda de frecuencia).
- Análisis de distribución de clases de dolor y análisis de desbalance por subpoblación.
- Análisis de reproducibilidad: comparación de features entre sujetos e inter-sesiones.
- Identificación de features redundantes mediante análisis de correlación de Pearson y mutual information.

Entregables

- Informe EDA con visualizaciones espectrales, topográficas y estadísticas.
- Lista de features candidatas por modalidad y subpoblación, con justificación neurofisiológica.
- Reporte de análisis de desbalance de clases y estrategia de mitigación propuesta.

8.4. Fase 4: Diseño, Entrenamiento y Validación de Modelos

Objetivos de la Fase

Diseñar, entrenar y validar los modelos de ML/DL para clasificación y cuantificación del dolor, y construir el Pain Index.

4A. Modelos por Modalidad — EEG

- Modelo baseline: SVM con features espectrales (PSD por banda, Hjorth parameters).
- Random Forest / XGBoost sobre features temporales y frecuenciales de EEG.
- CNN-EEG: red convolucional sobre representación tiempo-frecuencia (STFT/CWT) de señales EEG.
- LSTM / Transformer sobre secuencias temporales de EEG para captura de dinámica temporal del dolor.
- EEGNet (Lawhern et al., 2018): arquitectura CNN compacta diseñada específicamente para señales EEG.

4B. Modelos por Modalidad — Autonómica

- Modelo HRV: RF/XGBoost sobre features de HRV temporal (SDNN, RMSSD, pNN50) y frecuencial (LF/HF ratio).
- Modelo GSR: extracción de SCR (respuesta galvánica fásica) y tonic level; clasificación con SVM/RF.
- Modelo multisignal autonómico: fusión de HRV + GSR + temperatura con modelo ensemble.

4C. Pain Index — Fusión Multimodal

- Fusión ponderada (Weighted Ensemble): combinación lineal de probabilidades de dolor de modelos EEG y autonómico con pesos optimizados por validación cruzada.
- Stacking: meta-modelo entrenado sobre las salidas de los modelos base (EEG + autonómico).
- Attention-based fusion: mecanismo de atención aprendible que pondera la contribución de cada modalidad según la calidad de la señal en cada ventana temporal.
- Calibración del Pain Index: transformación de la salida del modelo a escala 0-10 calibrada contra NRS/CPOT.

4D. Modelos Especializados por Subpoblación

- Neonatos: modelo ajustado para EEG con maduración cortical incompleta; transfer learning desde modelo adulto.
- UCI sedados: modelo con variable de contexto de medicación sedante (propofol, midazolam, fentanyl dosis).
- Demencia: modelo ajustado para señal EEG con degeneración neuronal; features de conectividad cortical de baja frecuencia.

Estrategia de Validación

- Validación cruzada estratificada k-fold ($k=5$ o 10) por sujeto (leave-one-subject-out).
- Métricas: AUC-ROC, accuracy, F1-score, sensibilidad, especificidad, MCC, R^2 y MAE (para regresión del PI).
- Test de significancia estadística entre modelos (Wilcoxon signed-rank test).
- Análisis de equidad: comparación de AUC por subgrupo demográfico y subpoblación.

Entregables

- Modelos entrenados, validados y versionados (MLflow).
- Pain Index v1: modelo de fusión calibrado con métricas de rendimiento documentadas.
- Informe comparativo de modelos con análisis estadístico de rendimiento.

8.5. Fase 5: XAI, Dashboard Clínico y Análisis de Equidad

Objetivos de la Fase

Implementar la explicabilidad del sistema, desarrollar el dashboard clínico y analizar la equidad del modelo.

Tareas Principales — XAI

- Implementación de SHAP values para el Pain Index: contribución de cada feature EEG y autónoma por predicción.
- GRAD-CAM sobre el modelo CNN-EEG: visualización de canales y regiones temporales más relevantes para la predicción de dolor.
- LIME: explicaciones locales para casos individuales de pacientes (especialmente útil para validación clínica).
- Análisis de coherencia neurológica: validar que los features más relevantes según SHAP sean consistentes con la literatura neurofisiológica del dolor (P300, N2, gamma synchronization).

Tareas Principales — Dashboard Clínico

- Diseño UX/UI del dashboard orientado al médico intensivista / neonatólogo (prototipo en Figma).
- Implementación del dashboard con visualización en tiempo real del Pain Index (gauge chart, trend line).
- Visualización de contribución de señales: topografía EEG activa, HRV trend, GSR response.
- Sistema de alertas configurables: umbral de PI para notificación de intervención analgésica.
- Panel de explicación XAI: 'El Pain Index es 7.2 porque gamma EEG en canal Cz se incrementó un 45%, HRV disminuyó y GSR mostró 3 SCR en los últimos 30s'.
- Módulo de reportes clínicos: exportación PDF/CSV del historial del Pain Index por turno.

Tareas Principales — Análisis de Equidad

- Evaluación de fairness del modelo por subpoblación (neonatos vs. UCI vs. demencia).
- Análisis de sesgo por sexo, edad y diagnóstico de base.
- Implementación de métricas de equidad: demographic parity, equal opportunity, equalized odds.

Entregables

- Dashboard clínico funcional con XAI, alertas y reportes.
- Informe de análisis XAI con validación neurofisiológica de features relevantes.
- Reporte de equidad del modelo con análisis de sesgo y estrategias de mitigación.

8.6. Fase 6: Análisis de Resultados, Interpretación e Informe Final

Objetivos de la Fase

Analizar e interpretar los resultados globales, elaborar el informe final y formular la propuesta de continuidad clínica.

Tareas Principales

- Análisis comparativo de modelos: Pain Index vs. escalas clínicas observacionales (CPOT, NIPS, FLACC).
- Interpretación clínica de los hallazgos: ¿qué biomarcadores son los más relevantes? ¿Difieren por subpoblación?
- Discusión de implicancias clínicas: potencial impacto en la reducción del infratratamiento del dolor y la sobredosis opioide.
- Análisis EVM final: desempeño real vs. planificado del proyecto.
- Elaboración del Informe Final del Proyecto.
- Formulación de la propuesta de continuidad: validación clínica formal con pacientes reales (siguiente fase).
- Presentación y defensa del proyecto ante comisión evaluadora.

Entregables

- Informe Final del Proyecto (incluye todas las fases y resultados).
- Presentación ejecutiva para defensa.
- Propuesta de Continuidad — Fase Clínica (protocolo de validación en pacientes reales).
- Repositorio GitHub documentado y público (código, modelos, pipeline, instrucciones de reproducción).

8.7. Herramientas Recomendadas

Categoría	Herramientas
Procesamiento EEG	MNE-Python, PyEEG, EEGLAB (MATLAB), NeuroKit2, YASA
Señales autonómicas	NeuroKit2, BioSPPy, HeartPy, pyEDFlib, wfdb (PhysioNet)
ML Clásico	scikit-learn (RF, SVM, XGBoost), imbalanced-learn (SMOTE), optuna (HPO)
Deep Learning	PyTorch, TensorFlow/Keras, EEGNet, tsai (Time Series AI), torchaudio
Transformers / Series de tiempo	Hugging Face (Informer, PatchTST), PyTorch Forecasting
XAI	SHAP, LIME, Captum (PyTorch), GRAD-CAM (torchcam), Alibi
MLOps	MLflow, DVC, Weights & Biases, GitHub Actions
Dashboard clínico	Streamlit, Dash (Plotly), Bokeh, Panel, Figma (prototipo UX)
Bases de datos	PostgreSQL (historiales), InfluxDB (series de tiempo), Redis (caché real time)
Visualización científica	MNE (topomaps), matplotlib, seaborn, plotly, mne-bids
Gestión del proyecto	GitHub Projects, Jira / Notion (ScrumBan), Microsoft Project (EVM)
LLMs de apoyo	Claude Pro (análisis de papers EEG/ML), ChatGPT Deep Research (estado del arte), Consensus (síntesis bibliométrica PubMed/WoS)

8.8. Conclusión

PainPredict Neuro aborda una de las problemáticas más críticas y éticamente urgentes de la medicina contemporánea: la imposibilidad de evaluar objetivamente el dolor en poblaciones que no pueden comunicarlo. Su enfoque basado en Machine Learning sobre señales EEG y biomarcadores autonómicos representa una apuesta de alto impacto científico y social, reflejada en su ranking global de 9.60/10 y sus métricas máximas de valor agregado y aporte.

El proyecto ofrece al equipo de trabajo una experiencia formativa de alta complejidad y relevancia, que integra conocimientos de neurociencia computacional, procesamiento de señales biomédicas, machine learning clínico, explicabilidad de modelos e ingeniería de software, en el contexto de un dominio con impacto directo en la calidad de vida de poblaciones vulnerables.

El prototipo desarrollado sentará las bases para una fase de validación clínica formal en colaboración con equipos médicos, con potencial de publicación en revistas indexadas de alto impacto (IEEE TBME, Journal of Pain, Critical Care Medicine) y de transferencia tecnológica hacia el sistema de salud.

9. Anexos

9.1. Bases de Datos y Referencias Iniciales

Referencias Bibliográficas Clave

Neurofisiología del Dolor y Biomarcadores EEG

- Iannetti, G.D., & Mouraux, A. (2010). From the neuromatrix to the pain matrix (and back). *Experimental Brain Research*, 205(1), 1-12.
- Mouraux, A., & Iannetti, G.D. (2018). The search for pain biomarkers in the human brain. *Brain*, 141(12), 3290-3307.
- Peng, W., et al. (2015). Electroencephalogram-based measures of cortical information storage, transfer and neuroplasticity in relation to pain and pain sensitivity. *Scientific Reports*, 5, 8895.
- Gram, M., et al. (2017). Prediction of post-operative opioid analgesia using clinical-and EEG-based biomarkers. *European Journal of Pain*, 21(9), 1576-1591.

Datasets y Benchmarks

- Walter, S., et al. (2013). The BioVid Heat Pain Database: Data for the advancement and systematic validation of an automated pain recognition system. *IEEE CYBCONF 2013*.
- Koelstra, S., et al. (2012). DEAP: A Database for Emotion Analysis using Physiological Signals. *IEEE TAFCC*, 3(1), 18-31.
- Hartley, C., et al. (2017). Nociceptive brain activity as a measure of analgesic efficacy in infants. *Science Translational Medicine*, 9(388).
- Johnson, A.E.W., et al. (2016). MIMIC-III, a freely accessible critical care database. *Scientific Data*, 3, 160035.

Machine Learning aplicado al Dolor

- Thiam, P., et al. (2019). Multi-modal pain intensity recognition based on the SenseEmotion database. *IEEE TAFCC*, 12(1), 241-254.
- Sikka, K., et al. (2015). Automated assessment of children's postoperative pain using computer vision. *Pediatrics*, 136(1), e124-e131.
- Kächele, M., et al. (2015). Adaptive confidence learning for the personalization of pain intensity estimation systems. *Evolving Systems*, 6(3), 195-206.
- Werner, P., et al. (2022). Automatic recognition methods supporting pain assessment: A survey. *IEEE TAFCC*, 13(4), 1798-1819.

XAI en Contextos Clínicos

- Lundberg, S.M., & Lee, S.I. (2017). A unified approach to interpreting model predictions (SHAP). *NeurIPS 2017*.
- Holzinger, A., et al. (2022). Explainable AI Methods — A Brief Overview. *International Workshop on Extending Explainable AI Beyond Deep Models and Classifiers*. Springer.

Bases de Datos para Búsqueda Bibliométrica

- PubMed / MEDLINE (pubmed.ncbi.nlm.nih.gov): Descriptores — 'pain assessment non-communicative', 'EEG pain biomarkers', 'nociception machine learning'.
- IEEE Xplore (ieeexplore.ieee.org): Descriptores — 'pain recognition EEG', 'automated pain assessment', 'physiological pain signals ML'.
- Scopus (scopus.com): Descriptores — 'objective pain assessment', 'EEG nociception deep learning', 'pain index ICU'.
- Web of Science (WoS): Descriptores — 'pain biomarkers', 'affective computing pain', 'neonate pain EEG'.
- PhysioNet (physionet.org): repositorio de datasets biomédicos de libre acceso con documentación clínica.
- OpenNeuro (openneuro.org): repositorio de datasets EEG/fMRI en formato BIDS.

9.2. Escalas Clínicas de Referencia para el Ground Truth

Escala	Población	Dominio Evaluado	Referencia
CPOT	Adultos en UCI sedados	Expresión facial, movimiento, tensión muscular, compliance ventilador	Gelinas et al., 2006
NIPS	Neonatos (0-6 meses)	Expresión facial, llanto, postura de brazos/piernas, estado de alerta	Lawrence et al., 1993
FLACC	Niños y adultos no verbales	Face, Legs, Activity, Cry, Consolability	Merkel et al., 1997
ABBEY	Demencia avanzada	Vocalización, expresión, lenguaje corporal, cambio conductual	Abbey et al., 2004
NRS (0-10)	Pacientes comunicativos	Autorreporte numérico (referencia de calibración del PI)	Farrar et al., 2001

9.3. Glosario de Términos Técnicos

Término	Definición
EEG	Electroencefalografía: registro de la actividad eléctrica cerebral mediante electrodos en el cuero cabelludo.
HRV	Heart Rate Variability: variabilidad de la frecuencia cardíaca, indicador de actividad del sistema nervioso autónomo.
GSR / EDA	Galvanic Skin Response / Electrodermal Activity: conductancia de la piel, indicador de activación autonómica simpática.
ICA	Independent Component Analysis: técnica para separar fuentes de señal independientes, usada para remover artefactos en EEG.
SCR	Skin Conductance Response: respuesta galvánica fásica (phasic), evento discreto en la señal GSR.
PSD	Power Spectral Density: densidad espectral de potencia, describe la distribución de energía de la señal por banda de frecuencia.
Pain Index (PI)	Índice de dolor continuo (0-10) generado por el sistema PainPredict Neuro, basado en la fusión de modelos EEG y autonómicos.
CPOT	Critical-Care Pain Observation Tool: escala conductual de dolor validada para adultos en UCI.
Knowledge Distillation	Técnica para comprimir un modelo profundo (teacher) en uno liviano (student) para despliegue eficiente.
EEGNet	Arquitectura CNN compacta diseñada para clasificación de señales EEG en dispositivos con recursos limitados.

Referencia del Marco de Trabajo

Magna, Oscar (2026). Marco de Trabajo para Proyectos de Titulación en modalidad de Investigación v3.

Depto. de Informática y Computación, Facultad de Ingeniería, Universidad Tecnológica Metropolitana (UTEM, Chile).